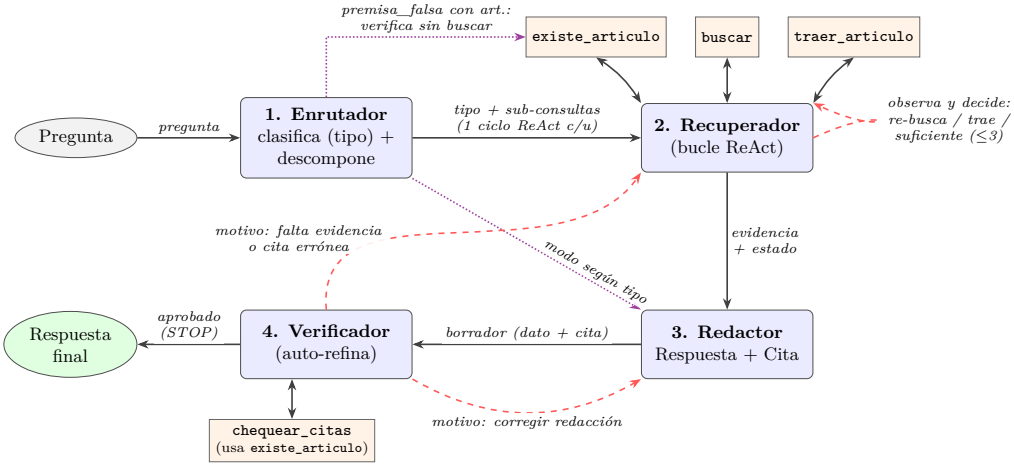
Sistema de agentes para el asistente de normativa de pregrado (Ingeniería UdeC)

Entregable 3: cuatro agentes con decisiones y bucles sobre Qwen3-4B, con ablación por técnica

Generative Artificial Intelligence (580694) | Segundo semestre 2026 | **Equipo:** Álvaro Contreras y Pablo Cortés

Repositorio: github.com/Pacortes2021/GENERATIVE-ARTIFICIAL-INTELLIGENCE-DELIVERABLE-1 **Video (3 min):** [Enlace de video]



Grafo de agentes. Negro: flujo principal (cada arista indica lo que se pasa); rojo discontinuo: bucles de decisión; violeta punteado: ramas decididas por el Enrutador; naranjo: herramientas. Parada: el Verificador aprueba, o se agotan los topes (ReAct ≤3 acciones por sub-consulta, ≤2 ciclos de corrección) y sale el último borrador *marcado como no aprobado*.

1. Continuidad con E1 y E2

Misma tarea y criterio: responder preguntas sobre el Reglamento General, el Reglamento Interno FI y el Calendario 2026 con el dato exacto y la cita que lo respalda (abstención si no existe o la premisa es falsa). Misma falla: con el RAG del E2 quedan excepciones omitidas, preguntas de cruce a medias y citas que no respaldan el dato. Se mantienen **Qwen3-4B** (NF4, sin thinking), el corpus, el recuperador E5 y la generación del E2; las herramientas envuelven ese recuperador.

Desviación declarada: se agregan 25 preguntas difíciles (cálculo, multi-salto, colisión léxica, premisa falsa) porque en las 50 originales el E2 ya acierta 40; el E2 se corrió *sin cambios* sobre ellas.

2. Agentes, decisiones y técnicas

Cada agente: una llamada a Qwen3-4B con prompt propio (`prompts/01-04`).

Enrutador. pregunta → JSON {tipo, sub-consultas, documentos}. *Decide*: premisa falsa con artículo → `existe_articulo` sin buscar; el tipo fija el modo del Redactor. *Técnica:* few-shot → preguntas de cruce respondidas a medias.

Recuperador. sub-consulta + última observación → evidencia + estado. *Decide* cada turno: buscar, traer, verificar o *suficiente*. *Técnica:* ReAct con acciones JSON → artículo equivocado por colisión léxica.

Redactor. pregunta + modo + evidencia (+ motivo del Verificador) → Respuesta / Condiciones / Fuente. Se abstiene si el estado es *no_existe* o *insuficiente*. *Técnica:* cadena de pensamiento en `<pensar>` (se elimina) → excepciones omitidas y cálculos.

Verificador. borrador + evidencia + `chequear_citas` → {aprobado, destino, motivo}. *Decide*: aprobar (STOP), devolver al Redactor o al Recuperador con el motivo. *Técnica:* self-refine con criterios explícitos → cita que no respalda el dato.

Por qué esta división: separar *buscar* de *redactar* permite re-buscar sin rehacer la redacción; separar *redactar* de *auditar* evita que el modelo apruebe su propio texto; cruce y premisa falsa necesitan otro camino desde el inicio.

3. Resultados y ablación

Mismas 75 entradas e igual criterio en todas las filas; cada ablación quita *una* técnica.

Configuración	50 orig.	25 dif.	Llam.
Prompting directo	1 (2 %)	0 (0 %)	1
RAG del E2	40 (80 %)	16 (64 %)	1
Agentes (completo)	**46 (92 %)**	**20 (80 %)**	10,6
sin few-shot	44 (88 %)	19 (76 %)	11,7
sin ReAct	45 (90 %)	18 (72 %)	5,0
sin CoT	46 (92 %)	19 (76 %)	9,3
sin Verificador	44 (88 %)	19 (76 %)	7,5

Llam.: llamadas al modelo por pregunta. *Sin Verificador*: primer borrador del Redactor (de las trazas; mismo prompt y semilla).

Frente al E2, pregunta a pregunta: en las 50 originales **7 mejoran y 1 empeora**; en las difíciles **6 mejoran y 2 empeoran**. El completo es el mejor o empata, pero ninguna ablación baja más de 2 preguntas por set: con $n = 50/25$ eso **no es estadísticamente significativo**; las técnicas se cubren entre sí.

4. Qué aporta cada técnica

ReAct: la mayor caída en las difíciles (−2); sin re-buscar falta evidencia (H05 no puede calcular la nota de titulación). **Few-shot:** sin ejemplos el Enrutador marca 6 premisas falsas en vez de 14 y nunca usa el tipo *cruce*; la herramienta `existe` compensa. **CoT:** empata en las originales y duplica el tiempo (55 vs. 110 s por pregunta en una T4), pero sin él falla un cálculo y acepta una premisa falsa (H06, H21). **Verificador:** +2 y +1 netos, pero su aprobación separa poco (89 % de acierto en lo aprobado vs. 82 % en lo rechazado).

5. Caso de falla (H03)

¿Cuántos días hay entre el inicio de clases y la fecha límite de modificación en cada semestre? Las fechas de inicio no quedan entre las 6 evidencias del Redactor, que inventa 31 y 262 días. El Verificador lo rechaza; el Redactor se abstiene y el Verificador lo devuelve dos veces al Recuperador, que repite búsquedas parecidas. Sale **no aprobada** tras 20 llamadas: el bucle evita un cálculo inventado, pero no corrige la recuperación.

6. Límites y reproducibilidad

El sistema se ajustó en tres iteraciones con mecanismos generales (no reglas por pregunta), diagnosticados con las trazas de estas mismas preguntas: las cifras describen el sistema final sobre preguntas conocidas, no su generalización. Corrección hecha con Claude siguiendo la pauta y los precedentes del E2, con motivo por fila y casos límite revisados por el equipo. Costo: ∼10 llamadas y ∼2 min por pregunta. El repositorio guarda prompts, trazas, planillas de corrección y el cuaderno de Colab.